# Fundamentos de Organización de Datos

Clase 7

# Agenda

- **Hashing**
  - Definición
  - Tipos
  - Propiedades
- **Propiedades**
  - Función de hash
  - Densidad / tamaño nodo
  - Tratamiento del overflow
- **Dispersión**
  - Estatica
  - Dinámica

# Hashing (Dispersión) → Introducción

## Necesitamos un mecanismo de acceso a registros con una lectura solamente

- Secuencia: N/2 accesos promedio
- Ordenado: $Log_2$ N
- Árboles: 3 o 4 accesos

## Clave Primarias → características

- No se repiten
- El resto de las claves actúan a través de ella
- Cuando se aprenda a modelar, tendrán más características que las hacen especiales

# Hashing (Dispersión) → Definición

Técnica para generar una dirección base única para una llave dada. La dispersión se usa cuando se requiere acceso rápido a una llave

Técnica que convierte la llave del registro en un número aleatorio, el que sirve después para determinar donde se almacena el registro.

Técnica de almacenamiento y recuperación que usa una función de hash para mapear registros en dirección de almacenamiento.

# Hashing (Dispersion) → definición

- Archivos secuenciales indizados
  - Archivo de datos
  - Archivo con indice primario
  - Archivos con indices univocos o secundarios
- Archivos directos
  - UN ACCESO
  - No puede haber estructuras adicionales
  - Se organiza EL archivo de datos
  - Solo puede organizarse por un UNICO criterio
  - Ese criterio es la clave primaria

# Hashing (Dispersión) → Definición

## Atributos del hash

- No requiere almacenamiento adicional (índice)
- Facilita inserción y eliminación rápida de registros
- Encuentra registros con muy pocos accesos al disco en promedio

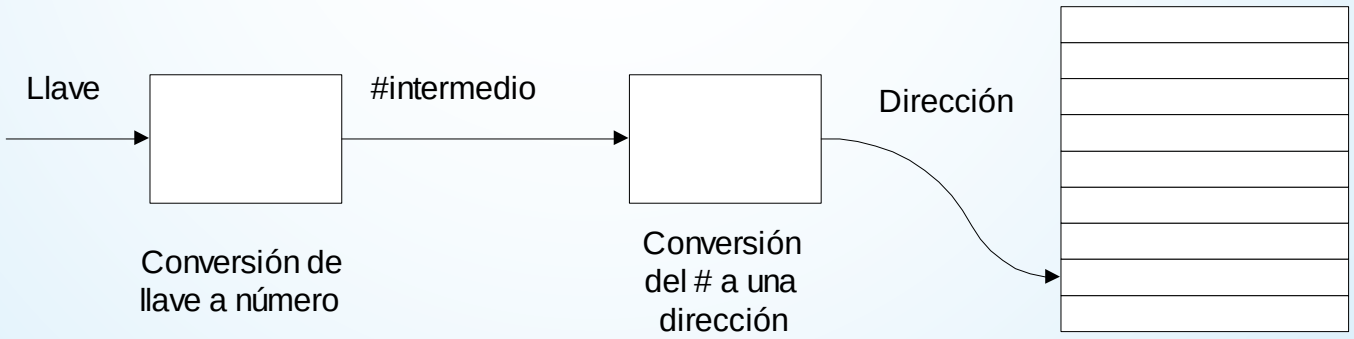

# Hashing (Dispersión) → Definción

## Costo

- No podemos usar registros de longitud variable
- No puede haber orden físico de datos
- No permite llaves duplicadas

## Para determinar la dirección

- La clave se convierte en un número casi aleatorio
- # se convierte en una dirección de memoria
- El registro se guarda en esa dirección
- Si la dirección está ocupada → colisión/overflow(tratamiento especial)

# Hashing (Dispersión) → Parámetros

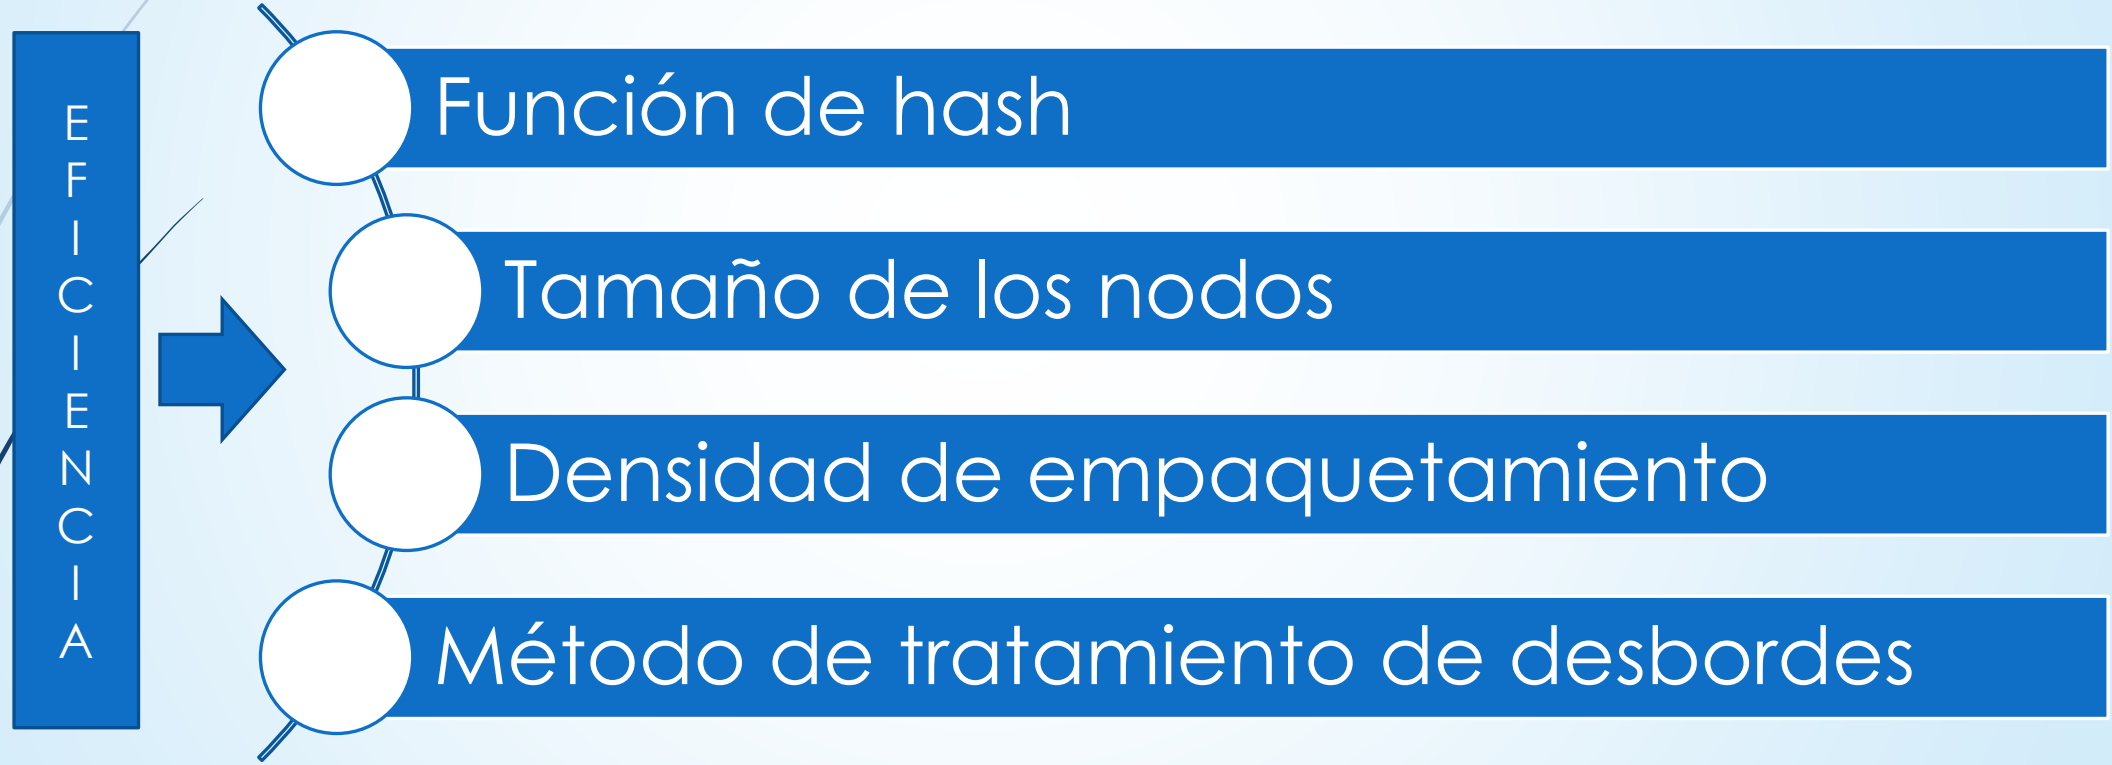

# Hashing (Dispersión) → Parámetros

## 1. Función de hash

- Caja negra que a partir de una clave se obtiene la dirección donde debe estar el registro.
- Diferencias con índices
  - Dispersión no hay relación aparente entre llave y dirección
  - Dos llaves distintas pueden transformarse en iguales direcciones (colisiones)

# Hashing (Dispersión) → parámetros

## Colisión:

- Situación en la que un registro es asignado a una dirección que está utilizada por otro registro

## Overflow

- Situación en la que un registro es asignado a una dirección que esta utilizada por otro registro y no queda espacio para este nuevo

## Soluciones

- Algoritmos de dispersión sin colisiones o que estas colisiones nunca produzcan overflow (perfectos) (imposibles de conseguir)
- Almacenar los registros de alguna otra forma, esparcir

# Hashing (Dispersión) → Parámetros

## Soluciones para las colisiones

- Esparcir registros: buscar métodos que distribuyan los registros de la forma más aleatoria posible
- Usar memoria adicional: distribuir pocos registros en muchas direcciones, baja la densidad de empaquetamiento:
  - Disminuye el colisiones y por ende overflow
  - Desperdicia espacio
- Colocar más de un registro por dirección: direcciones con N claves, mejoras notables

# Hashing (Dispersión) → Parámetros

## Algoritmos simples de dispersión

- Condiciones
  - Repartir registros en forma uniforme
  - Aleatoria (las claves son independientes, no influyen una sobre la otra)

## Tres pasos

- Representar la llave en forma numérica (en caso que no lo sea)
- Aplicar la función
- Relacionar el número resultante con el espacio disponible

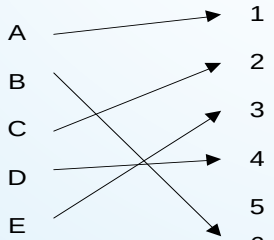

uniforme

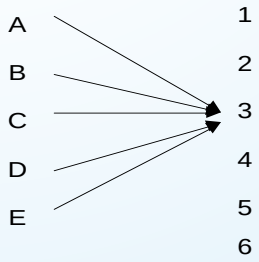

peor

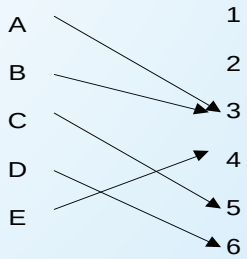

aceptable

# Hashing (Dispersión) → Parámetros

## 2. Tamaño de las cubetas

- Puede tener más de un registro
- A mayor tamaño
  - Menor overflow
  - Mayor fragmentación
  - Búsqueda más lenta dentro de la cubeta (este concepto realmente afecta al problema?)

# Hashing (Dispersión) → Parámetros

## 3. Densidad de empaquetamiento

- Proporción de espacio del archivo asignado que en realidad almacena registros
- DE = $\frac{\text{número de registros del archivo}}{\text{capacidad total del archivo}}$
- Densidad de empaquetamiento menor
  - Menos overflow
  - Más desperdicio de espacio

# Hashing → estimacion del Overflow

- Es necesario analizar el comportamiento de un archivo directo
- Cuando encontrar un registro requiere un solo acceso y cuando requiere mas cantidad de accesos
- Estimar el Overflow
  - Analizar probabilisticamente si la insercion de un registro genera o no colision
  - Analizar si la colisión genera o no overflow
- Es necesario
  - Conocer elementos básicos de probabilidades
  - Vamos a utilizar la distribucion de Poisson

# Hashing (Dispersión) → Parámetros

## Estimación del overflow → sabiendo que

- N # de cubetas,
- C capacidad de nodo,
- R # reg. Del archivo
- DE = $\frac{R}{C \times N}$
- Probabilidad que una cubeta reciba I registros (distribución de Poisson)

$$P(I) = \frac{R!}{I!*(R-I)!} * (\frac{1}{N})^I * (1-\frac{1}{N})^{R-I}$$

# Hashing (Dispersión) → Parámetros

**Por que? Cuál es la justificación de la fórmula anterior?**

- Supongamos que
  - A: no utilizar un cubeta particular
  - B: utilizar una cubeta en particular
- $P(B) = 1/N$ $P(A) = 1 – P(B) = 1 – 1/N$
- Si tenemos dos llaves?
  - $P(BB) = P(B) * P(B) = (1/N)^2$ (porque se puede asegurar esto?)
  - $P(BA) = P(B) * P(A) = (1/N) * (1 – 1/N)$
  - $P(AA) = P(A) * P(A) = (1 – 1/N)^2$

# Hashing (Dispersión) → Parámetros

## Si la secuencia fuera de tres claves

- $P(BBB) = P(B) * P(B) * P(B) = (1/N)^3$
- $P(BAA) = P(B) * P(A) * P(A) = (1/N) * (1-1/N)^2$
- $P(AAA) = P(A) * P(A) * P(A) = (1- 1/N)^3$
- Cuantas combinaciones? →8

# Hashing (Dispersión) → Parámetros

- En general → si fueran R claves
  - P(A…AB…B) siendo la suma de A y B igual a R
  - Que nos interesa → que I registros vayan a un nodo
  - ESTO QUE SIGNIFICA
    - B….B (I veces)
    - A…A ( R- I veces)
  - P(B) i veces
  - P(A) R-I Veces
  - $(1/N)^{i} * (1-1/N)^{R-I}$

# Hashing (Dispersión) → Parámetros

- Ahora analicemos la siguiente situacion
- P(B..B A..A) siendo I la cantidad de B y R-I la cantidad de A
  - $(1/N)^{i} * (1-1/N)^{R-I}$
- P(B A.. A B.. B) siendo I la cantidad de B y R-I la cantidad de A
  - $(1/N)^{i} * (1-1/N)^{R-I}$
- P( A.. A B.. B) siendo I la cantidad de B y R-I la cantidad de A
  - $(1/N)^{i} * (1-1/N)^{R-I}$
- Todas las anteriores combinaciones dan la misma probabilidad
  - Cuantas combinaciones se pueden hacer
  - R tomadas de a I ( R ! / ( I! * (R-I) ! ) )

# Hashing (Dispersión) → Parámetros

$$P(I) = \frac{R!}{I!*(R-I)!} * (\frac{1}{N})^I * (1-\frac{1}{N})^{R-I}$$

En general la secuencia de R llaves, que I caigan en un nodo es la probabilidad

$$(1/N)^I * (1-1/N)^{R-I}$$

Cuantas formas de combinar esta probabilidad hay (R tomadas de a I combinaciones)

$$\frac{R!}{I!*(R-I)!}$$

Función de Poisson: (probabilidad que un nodo tenga I elementos) R,N,I con la definición ya vista

$$P(I) = \frac{(R/N)^I * e^{-(R/N)}}{I!}$$

# Hashing (Dispersión) → Parámetros

## Análisis numéricos de Hashing

- En general si hay n direcciones, entonces el # esperado de direcciones con I registros asignados es N*P(I).
- Las colisiones aumentan con al archivo más "lleno"
  - Ej: N = 10000  R = 10000  DE = 1  100%

| | | | | |
|---|---|---|---|---|
| P(0)= 0.3679 | | | 3679 | |
| P(1)= 0.3679 | * | 10000 | 3679 | qué significa? |
| P(2)= 0.1839 | | | 1839 | |
| P(3)= 0.0613 | | | 613 | |

overflow = 1839 + 2 * 613 = 3065  (alto)

# Hashing (Dispersión) → Parámetros

## Ahora supongamos que el problema es

- R = 500 N= 1000 DE = 50%

| | | |
|---|---|---|
| P(0) = 0.607 | | 607 |
| P(1) = 0.303 | * 1000 | 303 |

saturación = N * [ 1 * P(2) + 2 * P(3) + 3 * P(4) + 4 * P(5) ] = 107

- **Saturación menor**

| densidad | overflow |
|---|---|
| 10% | 4.8% |
| 50% | 21.4% |
| 100% | 36.8% |

- **los números bajos de overflow (baja densidad) → muchas cubetas libres**

# Hashing (Dispersión) → Parámetros

**Que pasa si mantenemos la DE pero cambiamos ciertos valores**

- EJ:

R = 750
N = 1000
C = 1

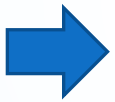

DE = 75%
R/N = 0,75

R = 750
N = 500
C = 2

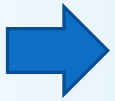

DE = 75%
R/N = 1,5

deben influir en la función de Poisson

saturación
c = 1 → 222 cubetas
c = 2 → 140 cubetas

- Cual es el tamaño de la cubeta?

# Hashing (Dispersión) → Parámetros

| DE | 1 | 2 | 5 | 10 | 100 |
|---|---|---|---|---|---|
| **10%** | 4.8 | 0.6 | 0.0 | 0.0 | 0.0 |
| **20%** | 9.4 | 2.2 | 0.1 | 0.0 | 0.0 |
| **30%** | 13.6 | 4.5 | 0.4 | 0.0 | 0.0 |
| **40%** | 17.6 | 7.3 | 1.1 | 0.1 | 0.0 |
| **50%** | 21.3 | 10.4 | 2.5 | 0.4 | 0.0 |
| **60%** | 24.8 | 13.7 | 4.5 | 1.3 | 0.0 |
| **70%** | 28.1 | 17.0 | 7.1 | 2.9 | 0.0 |
| **75%** | *29.6* | *18.7* | *8.6* | *4.0* | *0.0* |
| **80%** | 31.2 | 20.4 | 10.3 | 5.3 | 0.1 |
| **90%** | 34.1 | 23.8 | 13.8 | 8.9 | 0.8 |
| **100%** | 36.8 | 27.1 | 17.6 | 12.5 | 4.0 |

# Hashing (Dispersión) → Parámetros

## Tratamiento de Colisiones con Overflow

- Hemos visto que el % de overflow se reduce, pero el problema se mantiene dado que no llegamos a 0%

## Algunos métodos

- Saturación progresiva
- Saturación progresiva encadenada
- Doble dispersión
- Área de desborde separado

# Hashing (Dispersión) → Parámetros

## Saturación progresiva:

- Cuando se completa el nodo, se busca el próximo hasta encontrar uno libre.
- Búsqueda?
- Eliminación, no debe obstaculizar las búsquedas

# Hashing (Dispersión) → Parámetros

- Supongamos que la Fh general estas direcciones para las llaves dadas

Fh(alfa) = 50
Fh(beta) = 51
Fh(gamma) = 50
Fh(delta) = 50
Fh(epsilon) = 52
Fh(phi) = 51

Nodos de capacidad 2

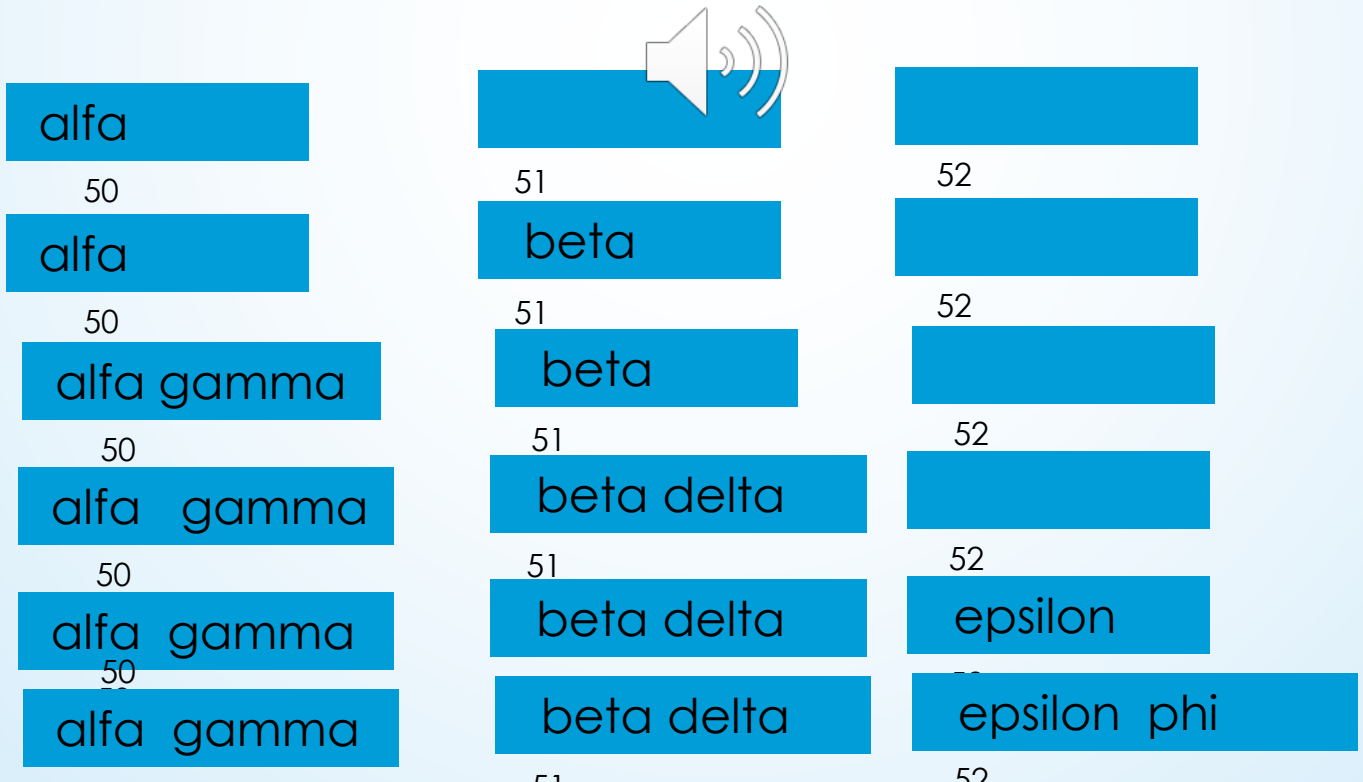

# Hashing (Dispersión) → Parámetros

- Supongamos que la Fh general estas direcciones para las llaves dadas

Fh(alfa) = 50
Fh(beta) = 51
Fh(gamma) = 50
Fh(delta) = 50
Fh(epsilon) = 52
Fh(phi) = 51

Nodos de capacidad 2

BORRO beta

# Hashing (Dispersión) → Parámetros

## saturación progresiva encadenada

- similar a saturación progresiva, pero los reg. de saturación se encadenan y "no ocupan" necesariamente posiciones contiguas
- Ejemplo

# Hashing (Dispersión) → Parámetros

- Supongamos que la Fh general estas direcciones para las llaves dadas

Fh(alfa) = 50
Fh(beta) = 51
Fh(gamma) = 50
Fh(delta) = 51
Fh(epsilon) = 50
Fh(phi) = 51

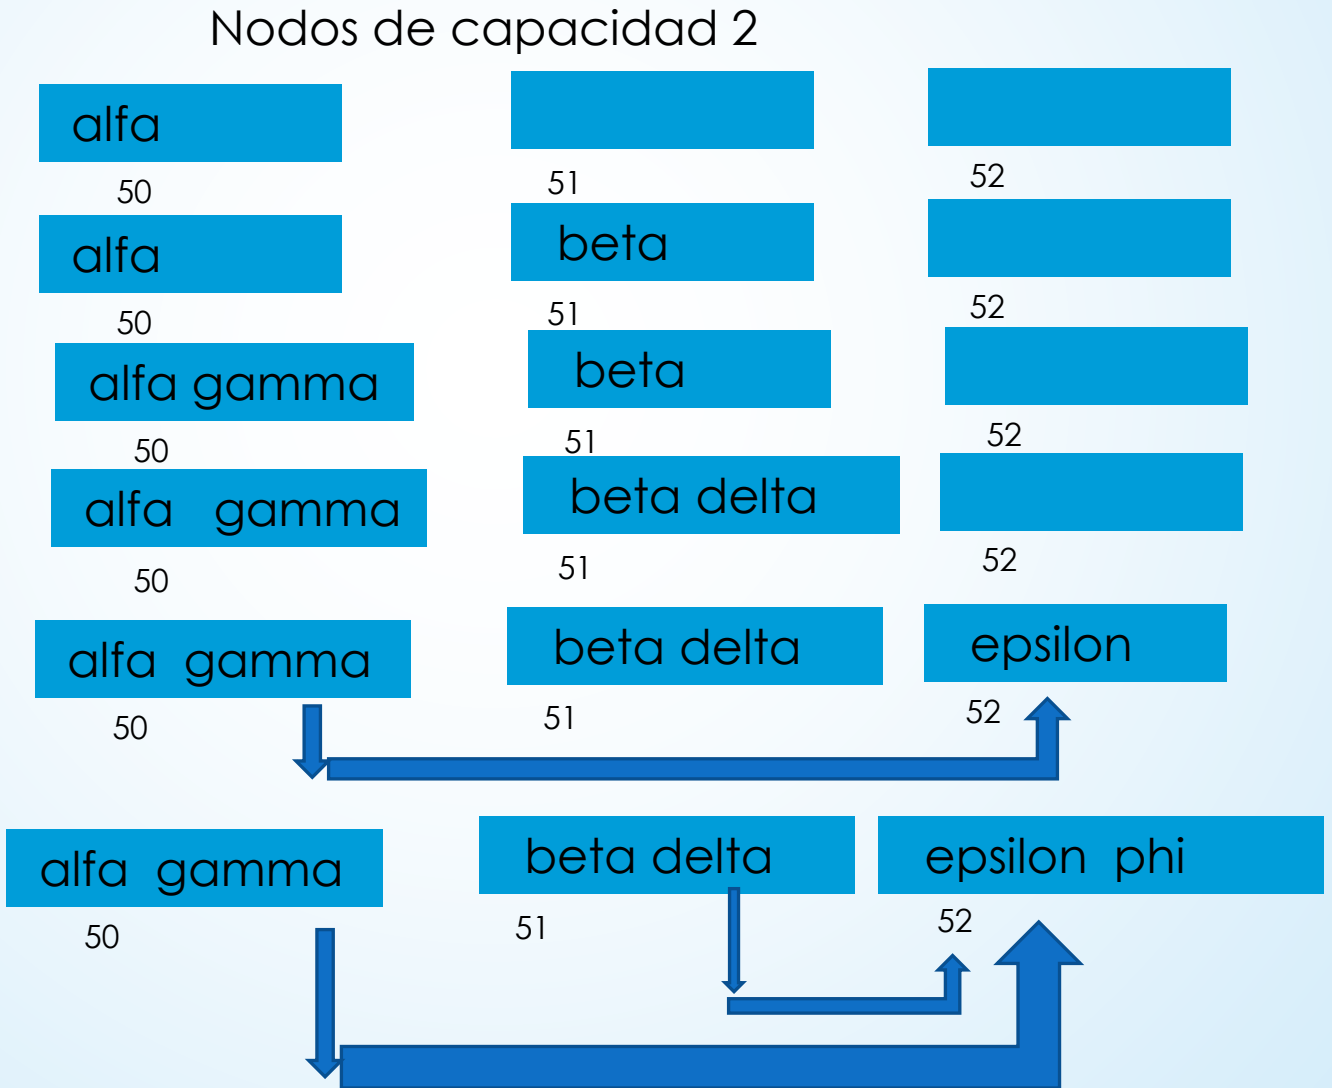

# Hashing (Dispersión) → Parámetros

## Dispersión doble:

- saturación tiende a agrupar en zonas contiguas, búsquedas largas cuando la densidad tiende a uno
- Solución almacenar los registros de overflow en zonas no relacionadas.
- esquema con el cual se resuelven overflows aplicando una segunda función a la llave para producir un N° C, el cual se suma a la dirección original tantas veces como sea necesario hasta encontrar una dirección con espacio.

# Hashing (Dispersión) → Parámetros

- Supongamos que la Fh general estas direcciones para las llaves dadas

Nodos de capacidad 2

F1h(alfa) = 50 F2h(alfa) = 5
F1h(beta) = 51 F2h(beta) = 10
F1h(gamma) = 50 F2h(gamma)= 20
F1h(delta) = 50 F2h(delta)= 8
F1h(epsilon) = 52 F2h(epsilon) = 7
F1h(phi) = 51 F2h(phi) = 3
F1h(tau) = 50 F2h(tau) = 10
F1h(rho) = 52 F2h(rho) = 5
F1h(tita) = 50 F2h(tita) = 2

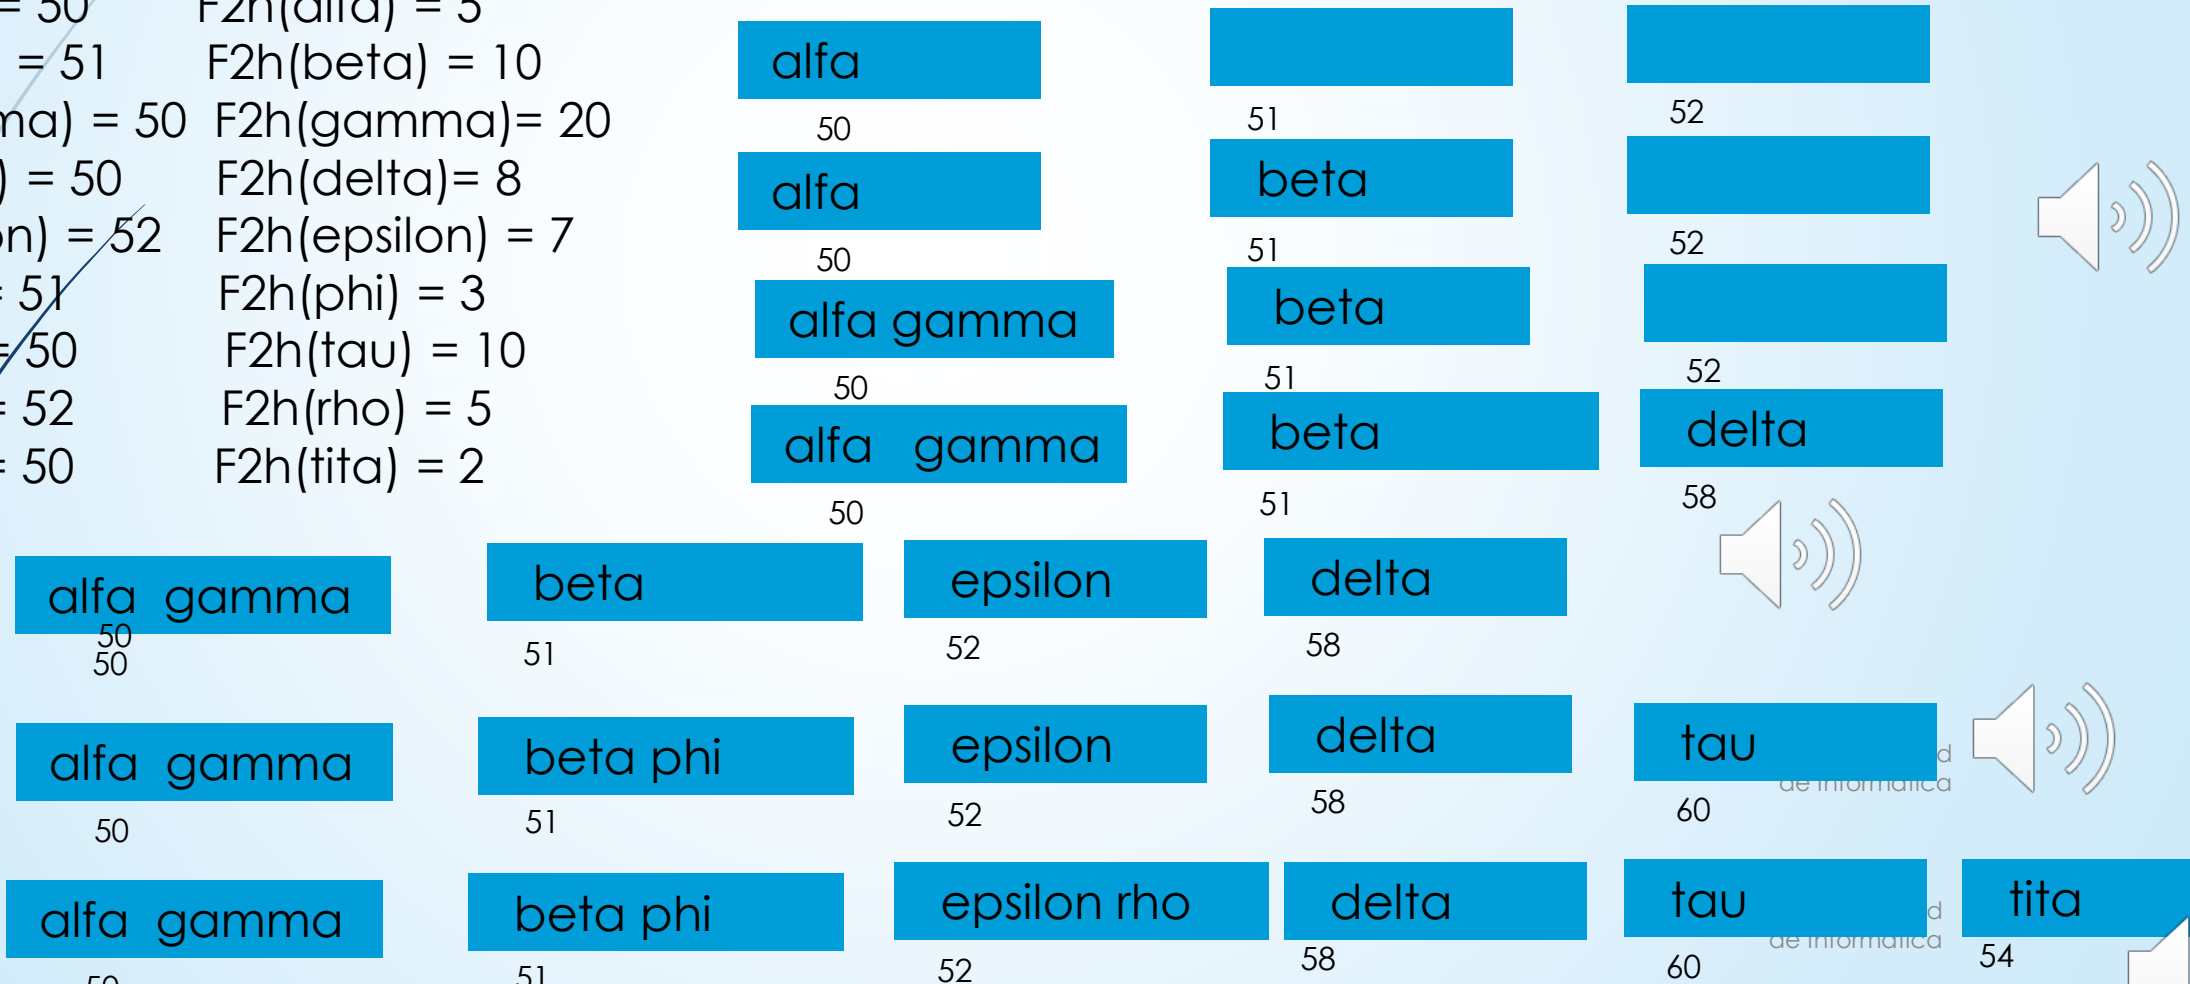

# Hashing (Dispersión) → Parámetros

## Encadenamiento en áreas separadas:

- No utiliza nodos de direcciones para los overflow, estos van a nodos especiales
- Ejemplo:
- Se mejora el tratamiento de inserciones o eliminaciones. Empeora el TAP.
- Ubicación del desborde
  - A intervalos regulares entre direcciones asignadas
  - Cilindros de desborde

# Hashing (Dispersión)

## Hash con espacio de direccionamiento estático

- Necesita un número de direcciones fijas, virtualmente imposible
- Cuando el archivo se llena
  - Saturación excesiva
  - Redispersar, nueva función, muchos cambios

## Solución → espacio de direccionamiento dinámico

- Reorganizar tablas sin mover muchos registros
- Técnicas que asumen bloques físicos, pueden utilizarse o liberarse.

# Hashing (Dispersión) → espacio dinámico

## Varias posibilidades

- Hash virtual
- Hash dinámico
- Hash Extensible

## Hash Extensible

- Adapta el resultado de la función de hash de acuerdo al número de registros que tenga el archivo, y de las cubetas necesitadas para su almacenamiento.
- Función:  Genera secuencia de bits (normalmente 32)

# Hashing (Dispersión) → espacio dinámico

## Como trabaja

- Se utilizan solo los bits necesarios de acuerdo a cada instancia del archivo.
- Los bits tomados forman la dirección del nodo que se utilizará
- Si se intenta insertar a una cubeta llena deben reubicarse todos los registros allí contenidos entre el nodo viejo y el nuevo, para ello se toma un bit más.
- La tabla tendrá tantas entradas (direcciones de nodos) como $2^i$, siendo i el número de bits actuales para el sistema.

# Hashing (Dispersión) → espacio dinámico (ejemplo

| Clave | Secuencia de bits |
|---|---|
| Alfa | .... 0011 0011 |
| Beta | .... 0110 0101 |
| Gamma | .... 1001 1010 |
| Epsilon | .... 0111 1100 |
| Delta | .... 1100 0001 |
| Tita | .... 0001 0110 |
| Omega | .... 1111 1111 |
| Pi | .... 0000 0000 |
| Tau | .... 0011 1011 |
| Lambda | .... 0100 1000 |
| Sigma | .... 0010 1110 |

# Ejemplo de hash extensible

Estado inicial del problema

- Un solo nodo es necesario para mi archivo
- Una sola dirección de disco debe tenerse
- Nodos de capacidad 2

Tabla --> nro bits = 0

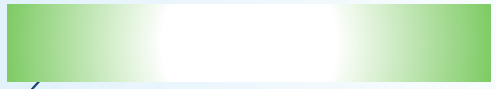

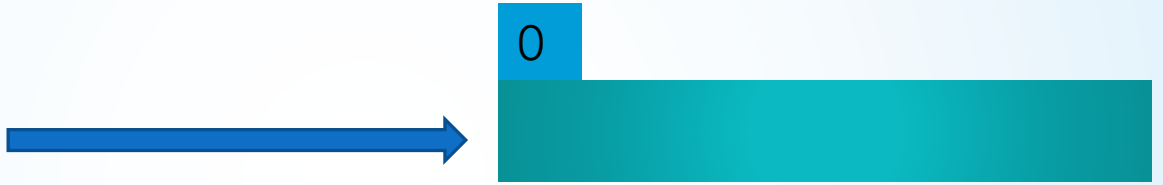


Llega ALFA → se aplica funcion de hash y se toman de la funcion de hash 0 bits

Tabla --> nro bits = 0

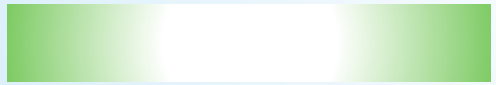


Llega BETA → se aplica funcion de hash y se toman de la funcion de hash 0 bits

Tabla --> nro bits = 0

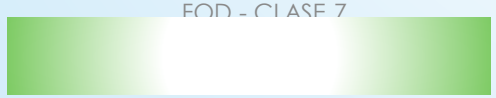

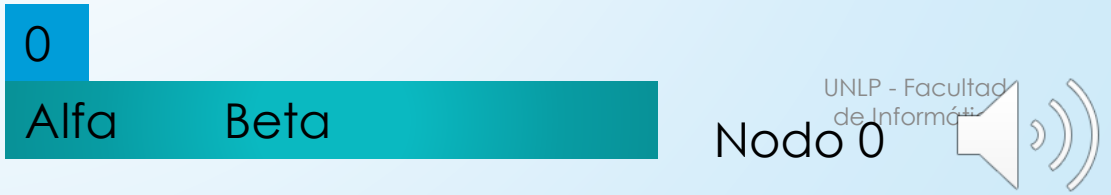

# Ejemplo de hash extensible



Llega GaMMA → se aplica funcion de hash y se toman de la funcion de hash 0 bits

Tabla --> nro bits = 0

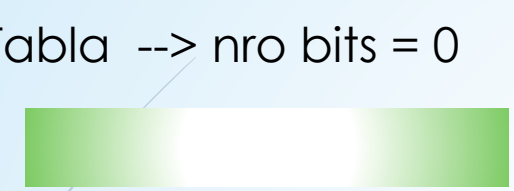


Nodo 0

Pero GAMMA No Cabe en el nodo 0 → OVERFLOW tratamiento especial

1 sumar uno al valor del nodo con overflow
2 se crea un nuevo nodo y se poner el mismo valor del nodo 0
3. Comparar el valor con el nro de bits de la tabla
4. Si es menor pasar al paso 7
5. Duplicar el tamaño de la tabla
6. Aumenatar en uno el nro de bits
7. Reacomodar direcciones
8. Reacomodar registros


Nodo 0


Nodo 1

Tabla --> nro bits = 1



Nodo 0


Nodo 1

Tabla --> nro bits = 1

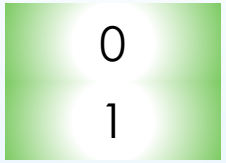


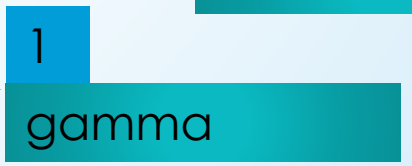


Nodo 0


Nodo 1

| Clave | Secuencia de bits |
|---|---|
| Alfa | .... 0011 0011 |
| Beta | .... 0110 0101 |
| Gamma | .... 1001 1010 |

# Ejemplo de hash extensible



| Epsilon | .... 0111 1100 |
|---|---|

Tabla --> nro bits = 1

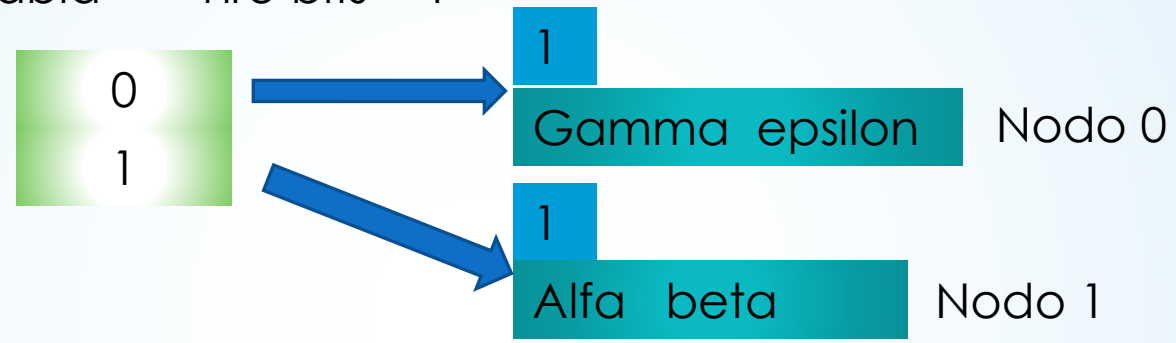


| Delta | .... 1100 0001 |
|---|---|

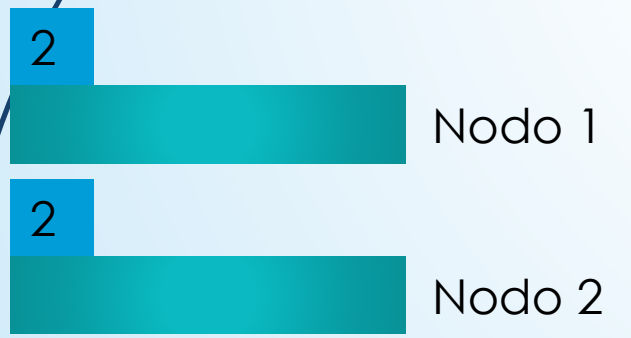


Tabla --> nro bits = 2

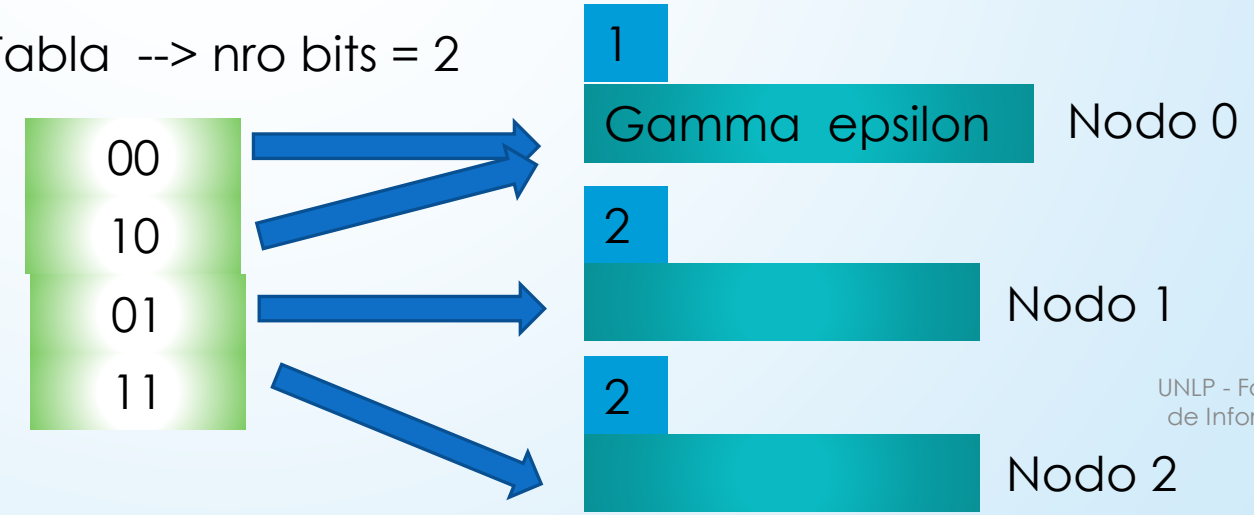

# Ejemplo de hash extensible



| | |
|---|---|
| **Alfa** | **.... 0011 0011** |
| Beta | .... 0110 0101 |
| **Delta** | **.... 1100 0001** |

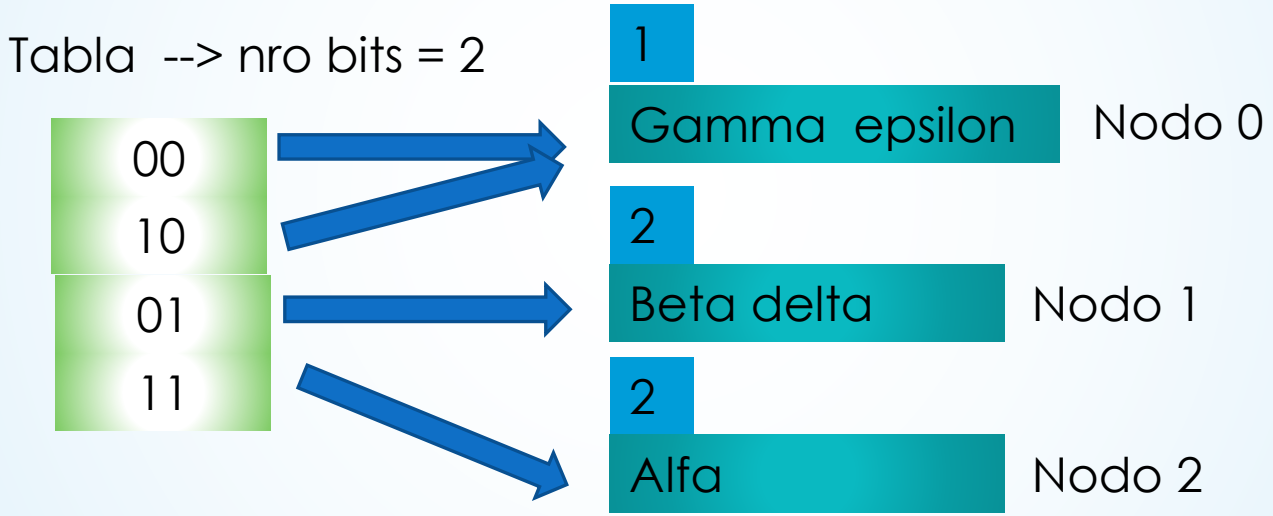

# Ejemplo de hash extensible



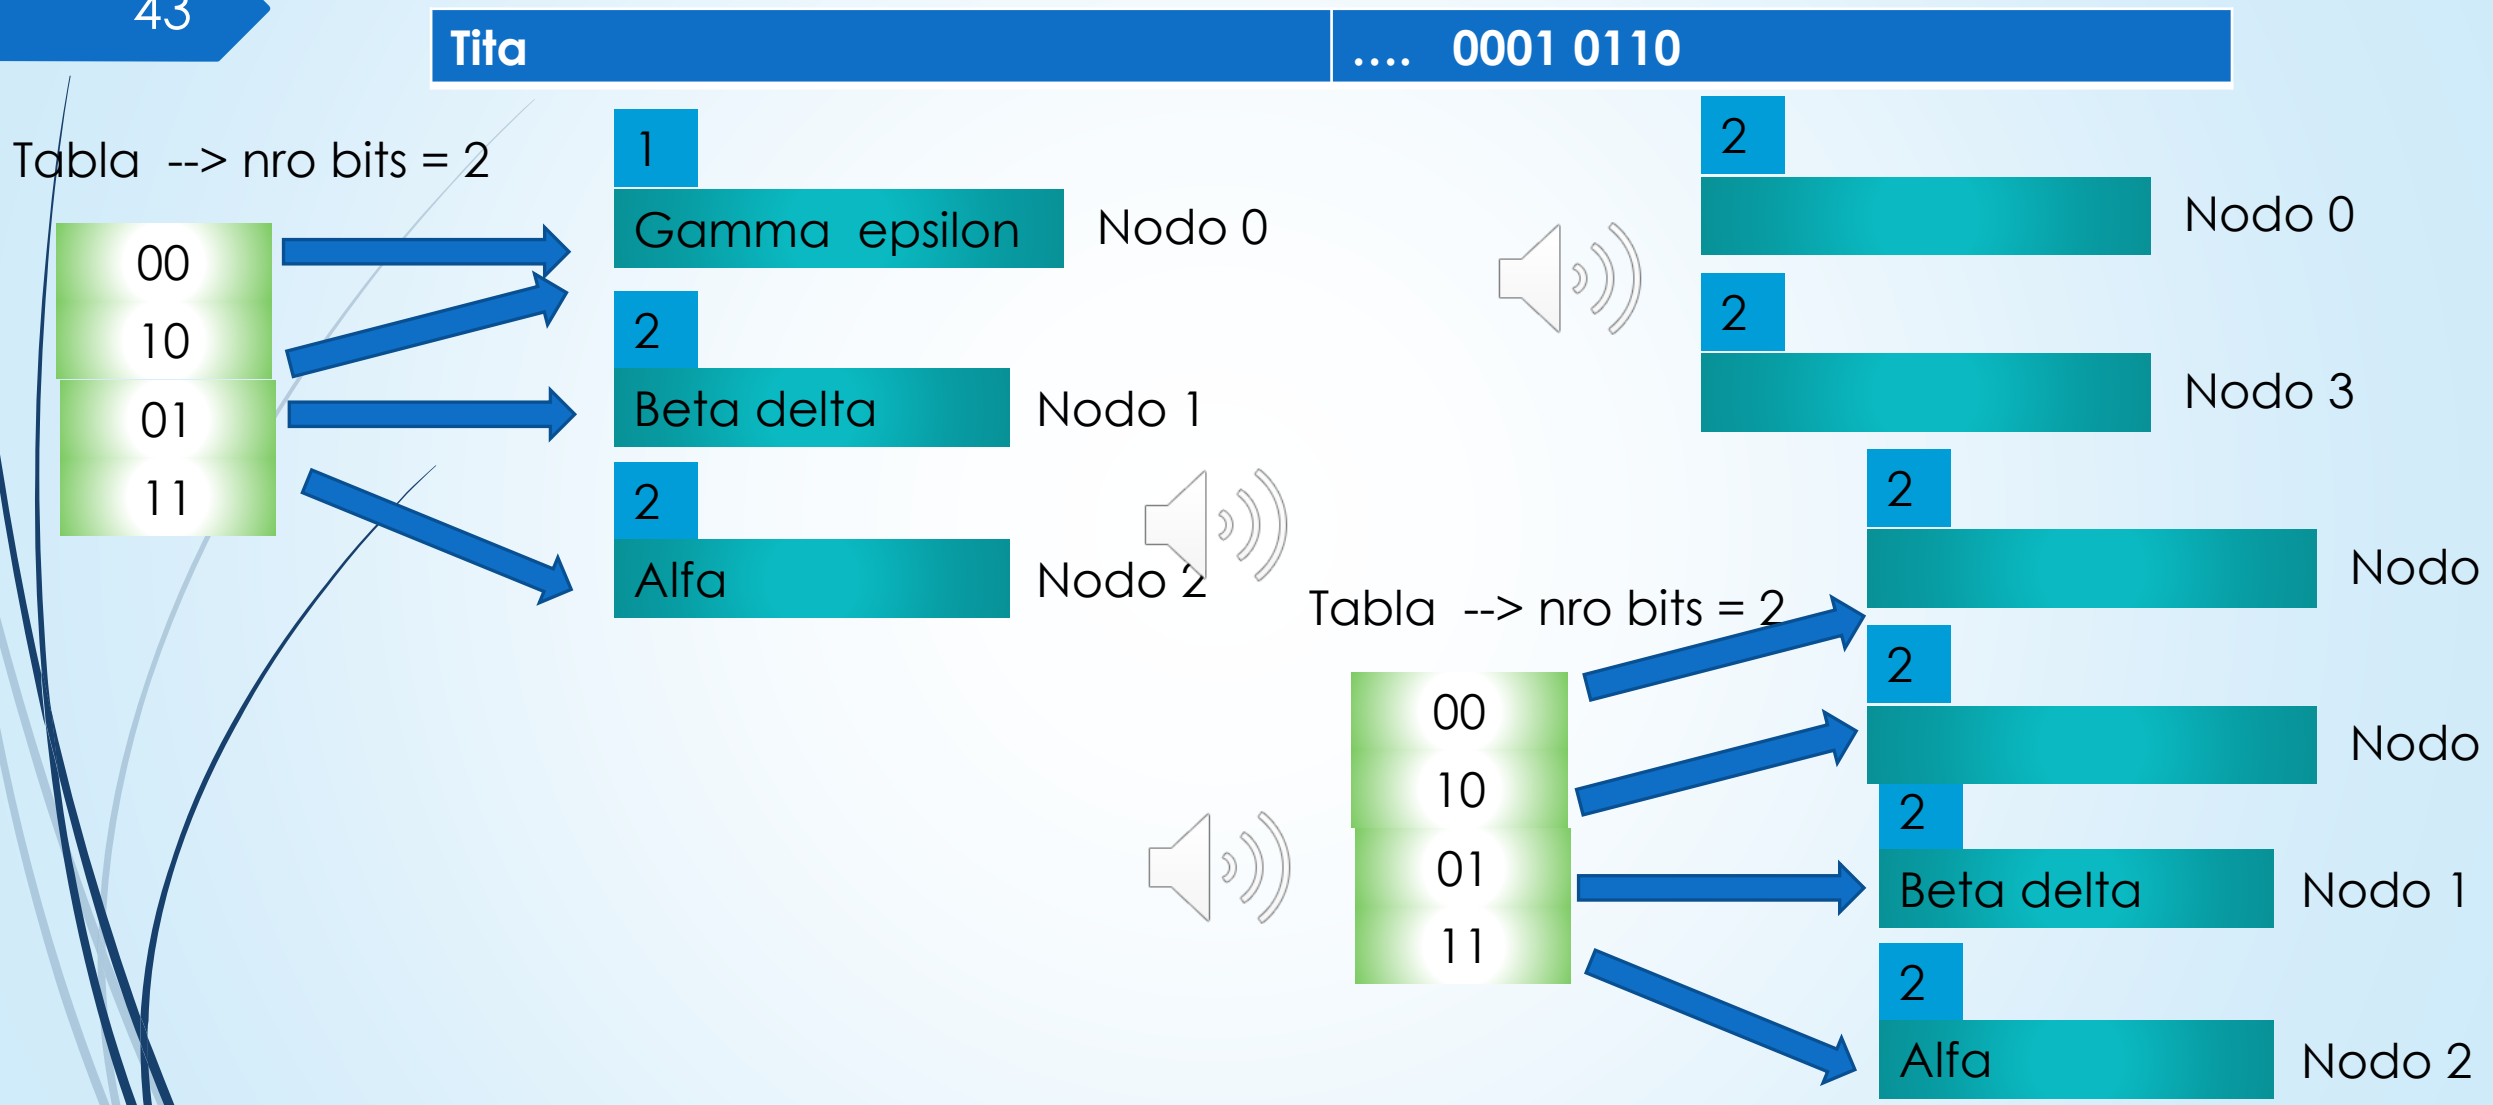

# Ejemplo de hash extensible



| Omega | .... 1111 1111 |
| --- | --- |
| Pi | .... 0000 0000 |

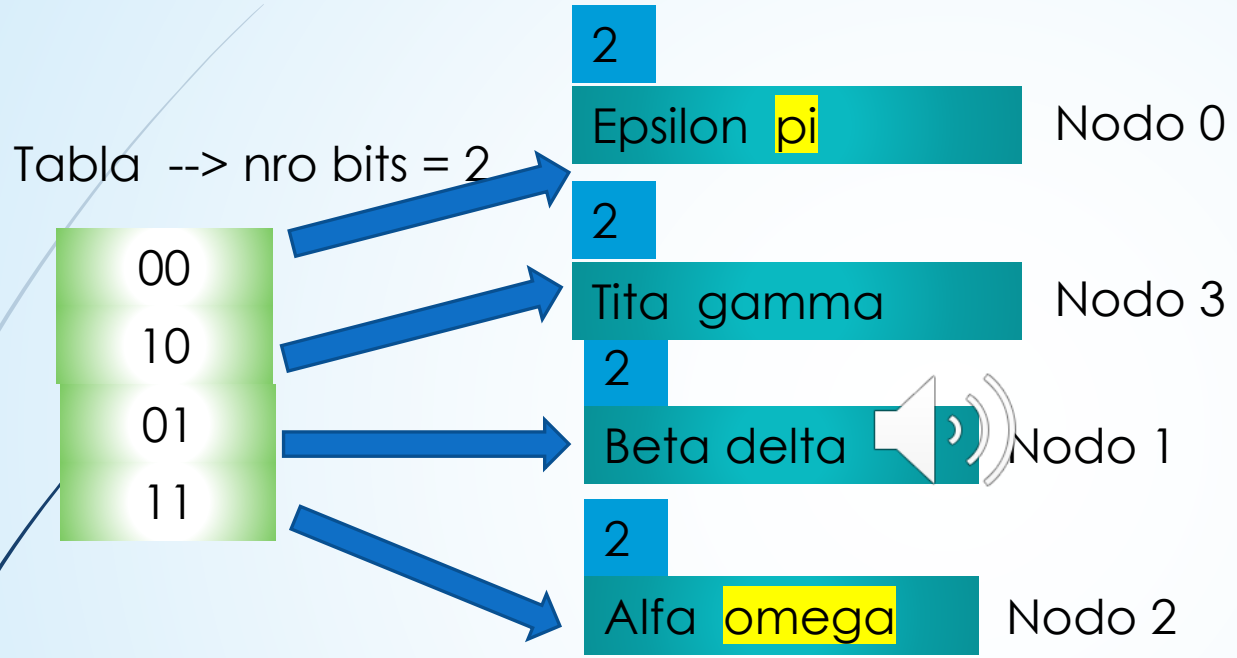

# Ejemplo de hash extensible



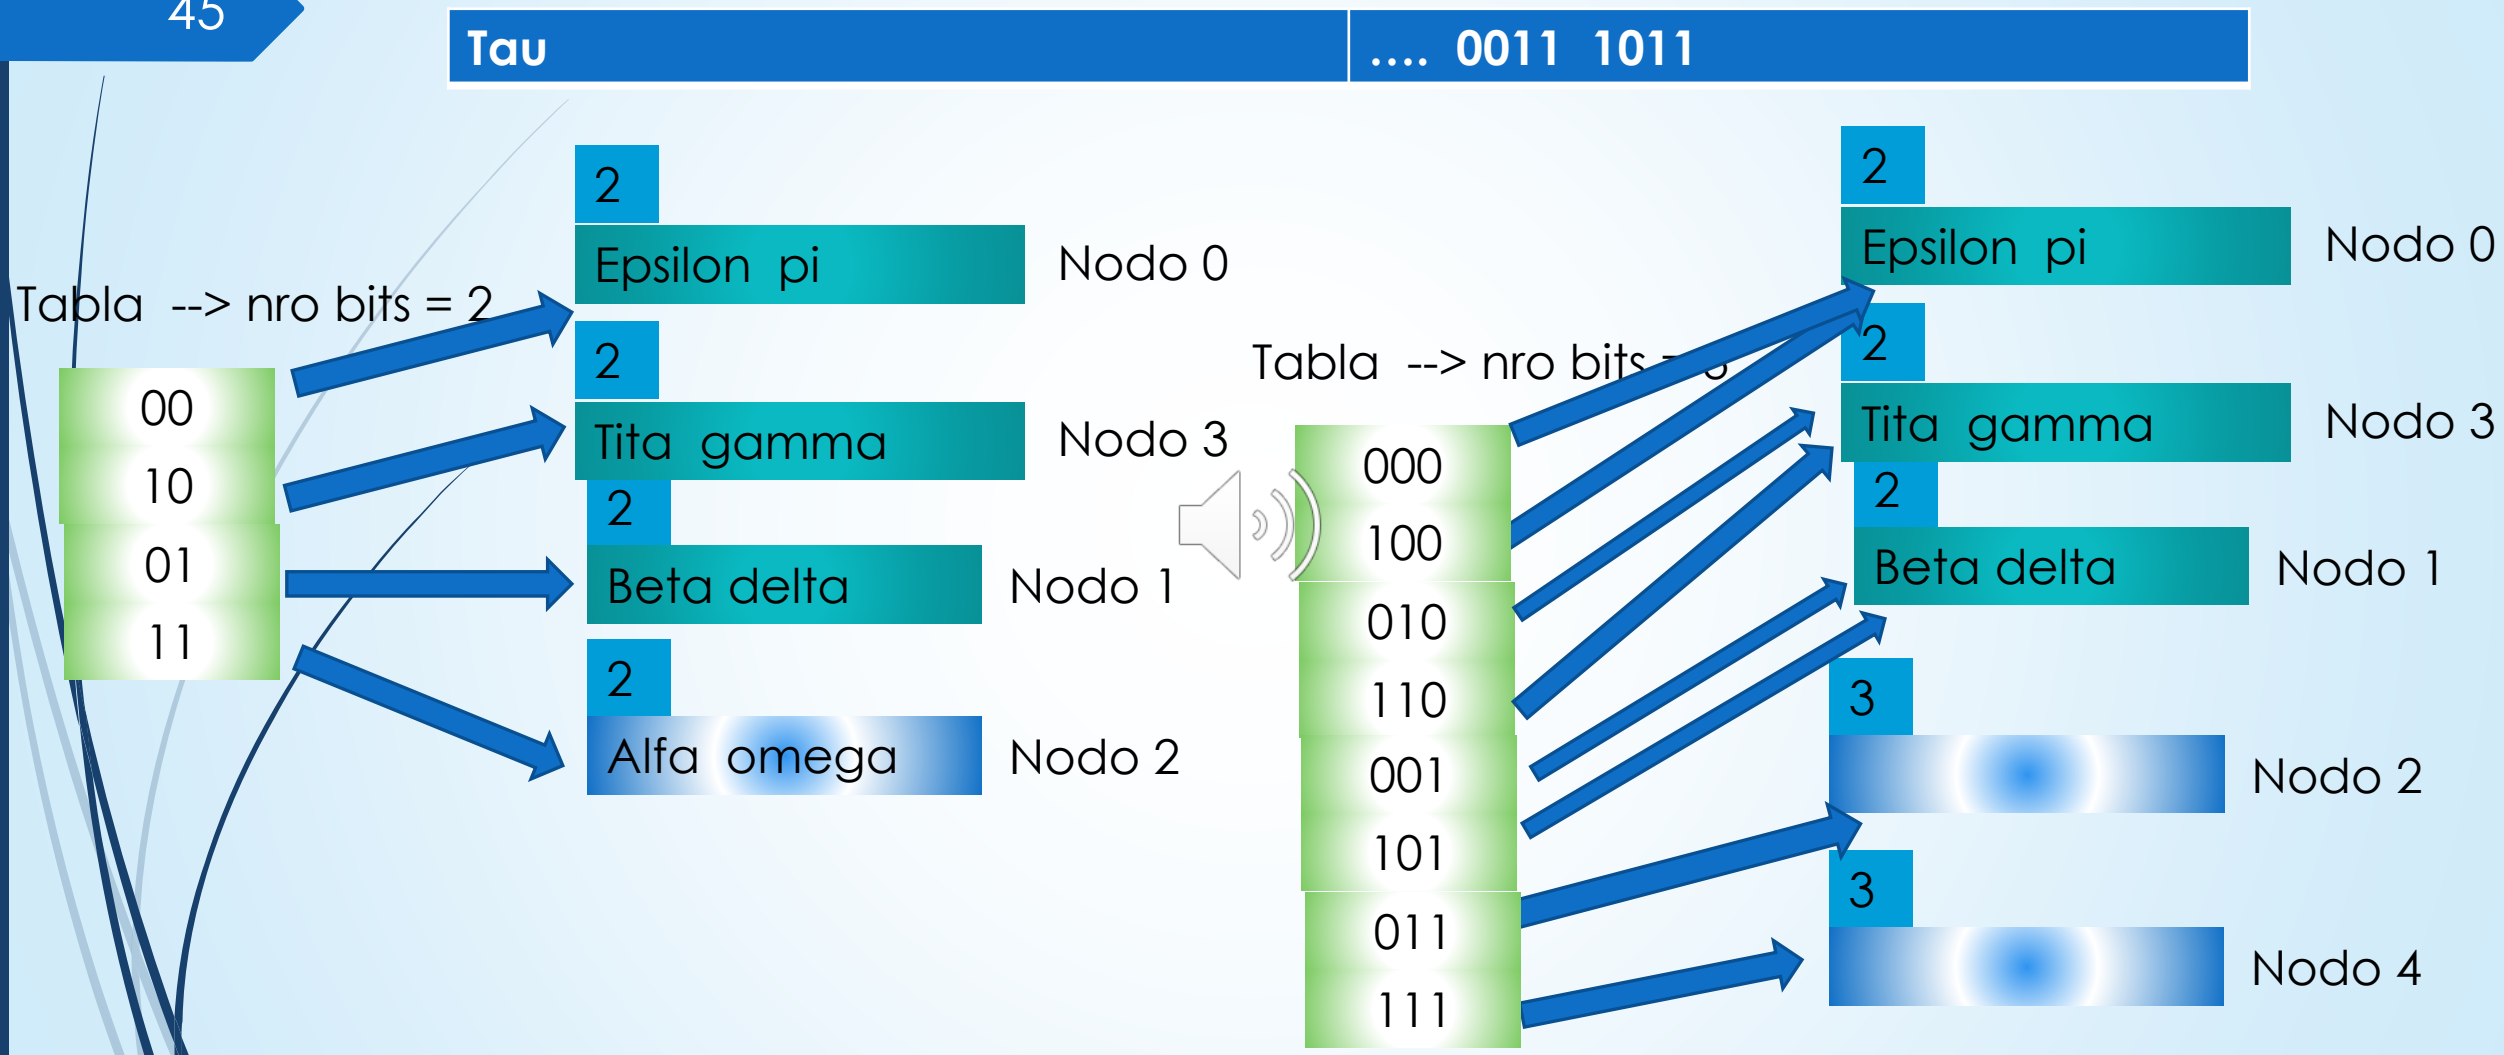

# Ejemplo de hash extensible



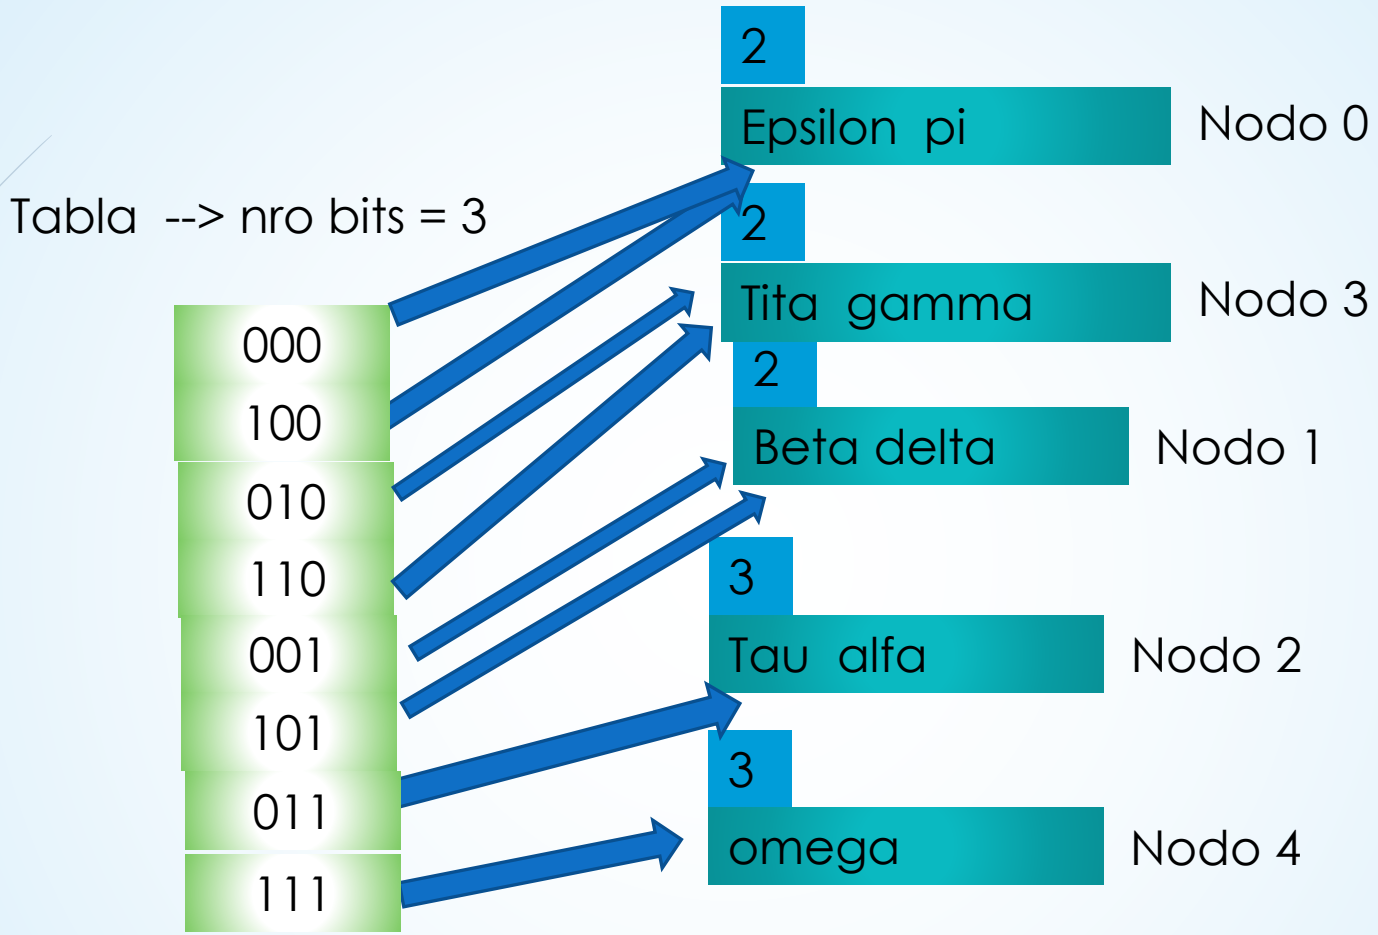

# Ejemplo de hash extensible



# Ejemplo de hash extensible

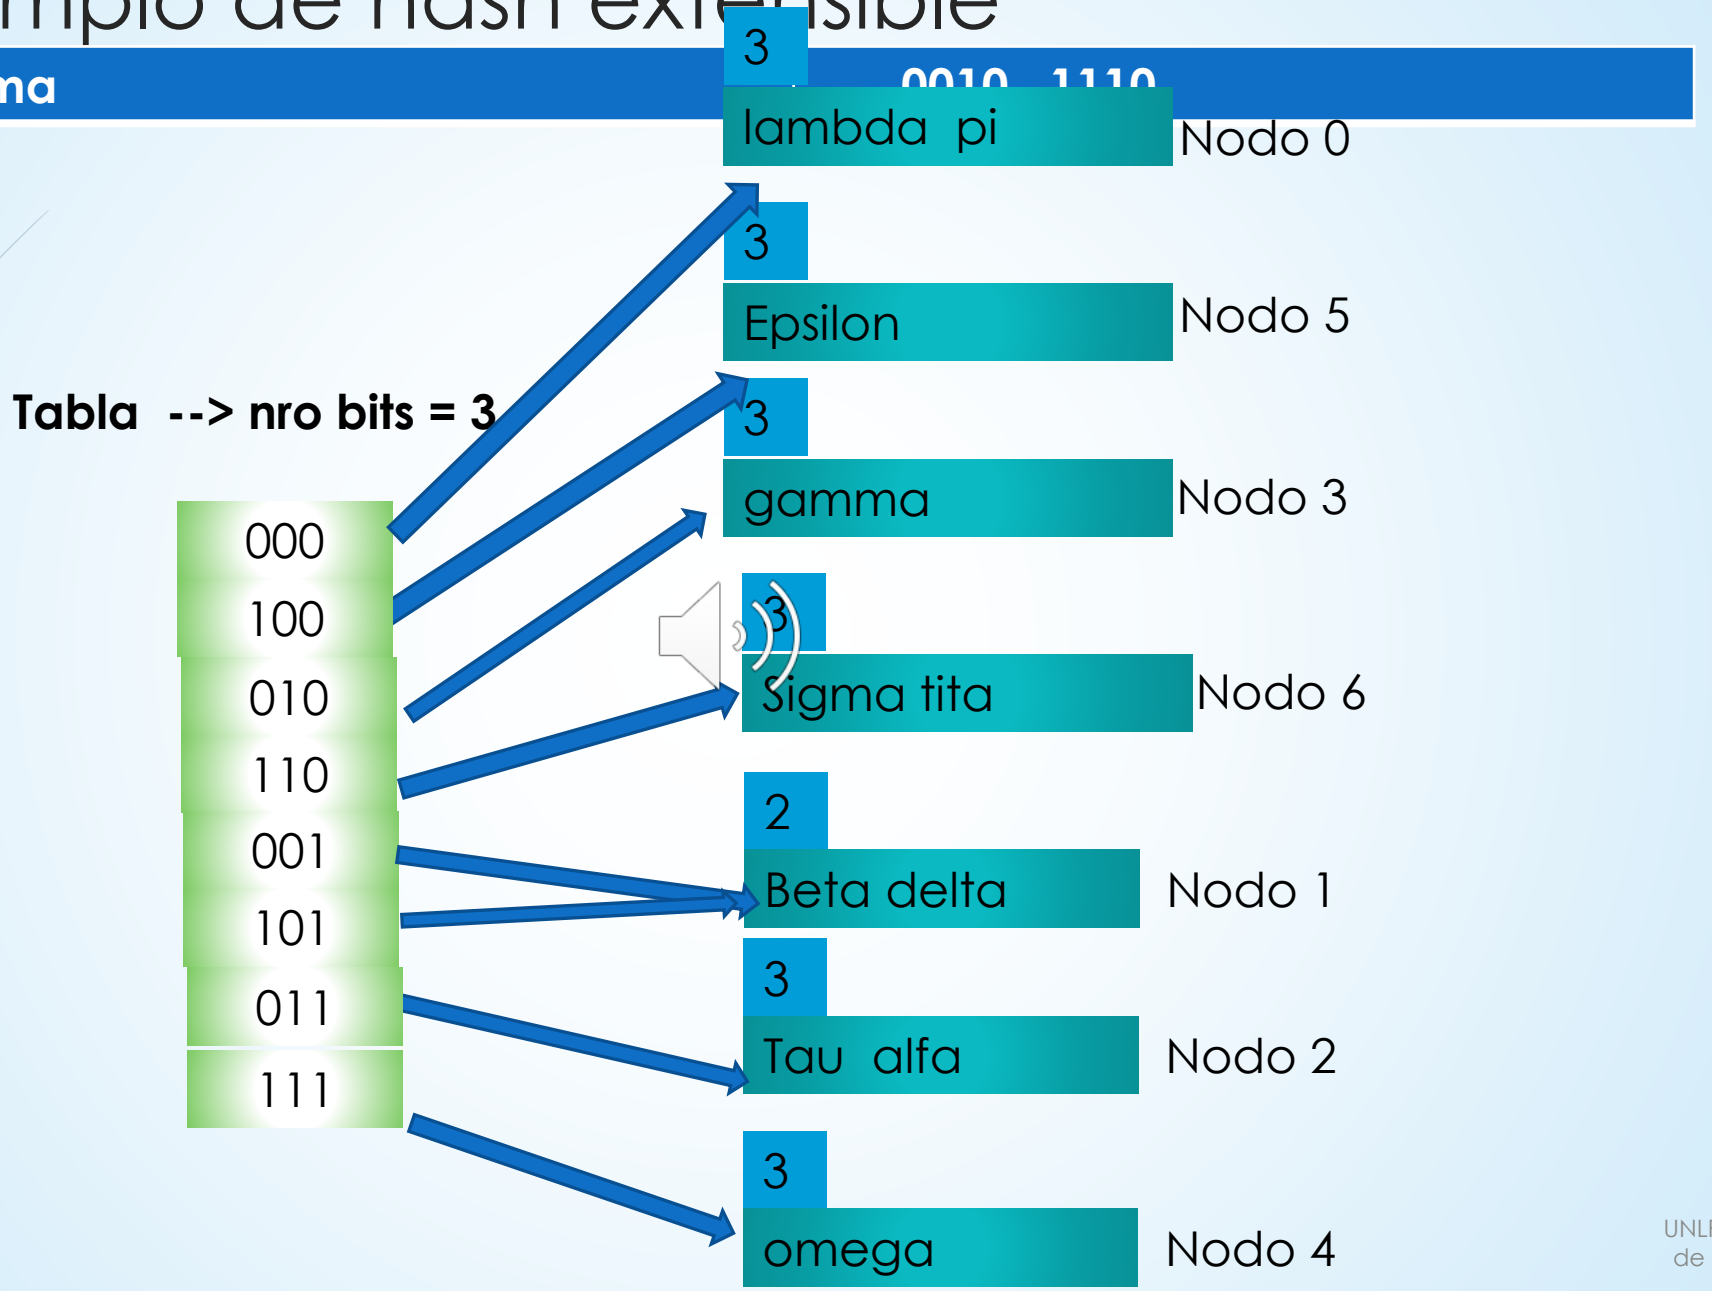

# Elección de organización

## Archivos

- Acomodar datos para satisfacer rápidamente requerimientos
- Accesos: resumen

| Organización | Acc.un reg. CP | Todos reg. CP |
|---|---|---|
| Ninguna | Lento | Lento |
| Secuencial | Lento | Rápido |
| Index sec. | Buena | Rápida |
| Hash | Rápido | lento |

# Elección de organización

## Elección de organización

- Captar los requerimientos de usuario
- Que examinar
  - Características del archivo
    - Número de registros, tamaño de registros
  - Requerimientos de usuario
    - Tipos de operaciones, número de accesos a archivos
    - Características del hard
      - Tamaño de sectores, bloques, pistas, cilíndros, etc.
    - Parámetros
    - Tiempo (necesario para desarrollar y mantener el soft, para procesar archivos)
    - Uso promedio (# reg. Usados/ #registros)